

## 9. Computer Vision


### 9.1 Object Detection

#### 9.1.2 You Only Look Once (YOLO)

עד שנת 2016 כל הגלאים (detectors) המבוססים על למידה עמוקה (כמו למשל R-CNN family) היו גלאים דו-שלביים – השלב הראשון יצר אלפי הצעות (proposals) למסגרות מלבניות החשודות כמכילות אובייקטים, ואלו הוזנו בזו אחר זו לשלב השני אשר דיוק את המסגרות וביצע סיווג לאובייקטים המוכללים בהן. ארכיטקטורת YOLO, הנגזרת מראשי התיבות של YOU ONLY LOOK ONCE, הוצגה על ידי ג'וזף רדמון ב-2016, והייתה הגלאי הראשון שמורכב משלב יחיד, ובו הרשת מנבאת את המסגרות וגם מסווגת את האובייקטים שבתוכן בבת אחת. בנוסף, ארכיטקטורת YOLO מתאפיינת במיעוט פרמטרים וכמות פעולות אריתמטיות. היא אמנם משלמת על המבנה הרזה והאלגנטי שלה בדיוק נמוך יותר, אך המהירות הגבוהה (שנובעת בעיקר מהיעדר האילוץ לעבד מסגרת יחידה בשלב השני בכל מעבר של הלולאה) הפכה את גישת השלב היחיד לאטרקטיבית מאוד, במיוחד למעבדים קטנים כדוגמת מכשירי mobile. בעקבות עבודה זו פותחו גלאים רבים על בסיס שלב יחיד, כולל גרסאות מתקדמות יותר של YOLO (הגרסה המתקדמת ביותר כיום היא v5).

#### NMS (Non-Maximum Suppression)

כמעט כל אלגוריתם של זיהוי אובייקטים מייצר מספר רב של מסגרות חשודות, כאשר רובן מיותרות ויש צורך לדלל את מספרן. הסיבה ליצירת מספר גדול של מסגרות נובע מאופי פעולת הגלאים. בזכות התכונות הלוקאליות של פעולת הקונבולוציה, מפת הפיצ'רים במוצא הגלאי ניתנת לתיאור כמטריצת משבצות כאשר כל משבצת שקולה לריבוע של הרבה פיקסלים בתמונה המקורית. רוב הגלאים פועלים בשיטת עוגנים (anchors), כאשר כל משבצת במוצא הגלאי מנבאת מספר קבוע של מסגרות שעשויות להכיל אובייקט (למשל, ב-YOLOv2 המספר הוא 5, ובגרסאות המתקדמות יותר המספר הוא 3). השיטה הזו יוצרת אלפי מסגרות שרק מעטות מהן הן משמעותיות. בנוסף – יש ריבוי של מסגרות דומות בסביבת כל אובייקט (למשל – YOLOv3 מנבאת יותר מ-7000 מסגרות לכל תמונה). אחת הדרכים הפופולריות לסנן את אלפי המסגרות ולהשאיר רק את המשמעותיות נקראת NMS. בשיטה זו מתבצעת השוואה בין זוגות של קופסאות מאותה המחלקה (למשל – חתול), ובמידה שיש ביניהן חפיפה גבוהה – מוחקים את המסגרת בעלת הוודאות הנמוכה ביותר ונשארים רק עם המסגרת בעלת רמת הוודאות הגבוהה. שיטה זו בזבזנית בחישוב (סיבוכיות פרופורציונלית לריבוע מספר המסגרות) ואינה חלק מהמודל המתאמן, אך עם זאת הינה אינטואיטיבית יחסית למימוש, ומשום כך נמצאת בשימוש נפוץ בגלאים, כולל ב-YOLO.



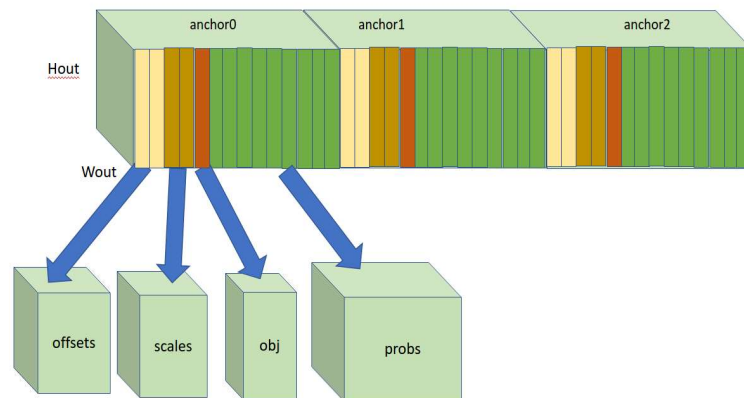
איור 9.1 אלגוריתם NMS.

#### YOLO Head

כמו רוב הגלאים, YOLO הינו מבוסס-עוגנים (anchor-based), שהינן תיבות מלבניות קבועות ושונות זו מזו בצורתן. לכל עוגן מוקצה מקטע של פיצ'רים במפת המוצא של הרשת וכל הניבויים במקטע הזה מקודדים כסטיות (offsets) ביחס לממדי העוגן. כפי שניתן לראות באיור 9.2, הפיצ'רים של כל תא מרחבי במפת המוצא מחולקים למקטעים על פי העוגנים (שלושה עוגנים במקרה הזה).

ניבוי הוא מסגרת שמרכזה נמצא בנקודה כלשהי בשטח התא (השקול לריבוע של מספר פיקסלים בתמונה המקורית). ההסטה המדויקת של מרכז המסגרת ביחס לתא ניתנת על ידי שני הפיצ'רים הראשונים ברצף. לוג המימדים של הקופסא (ביחס לממדי העוגן) ניתן באמצעות שני הפיצ'רים הבאים ברצף. הפיצ'ר החמישי לומד את מידת ה-objectness, כפי שהוסברה לעיל. שאר הפיצ'רים ברצף של העוגן הנ"ל הם ההסתברויות המותנות לכל מחלקה (אם

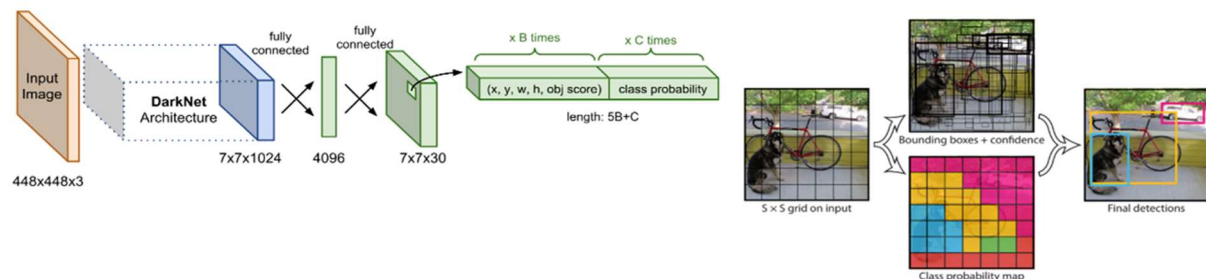
אוסף הנתונים מכיל 80 מחלקות, יהיו 80 פיצ'רים כאלה). על מנת לקבל רמת ודאות סופית, יש להכפיל את מדד ה-objectness במדד ההסתברות המותנה לכל מחלקה.



איור 9.2 ראש YOLO.

## YOLOv1

מודלי YOLO מבוססים על גרסאות Backbone הנקראות Darknet ומשמשות לעיבוד פיצ'רים מתוך התמונה, ומראש detection המקבל את הפיצ'רים האלה ומתאמן לייצר מהם ניבויים למסגרות סביב אובייקטים. המודל מחלק את התמונה לרשת בעלת  $S \times S$  משבצות, כאשר כל משבצת מנבאת  $N$  מסגרות של אובייקטים בשיטת העוגנים, כאמור לעיל. כל ניבוי כולל את מספר ערכים: הסטת הקואורדינטות  $x, y$  של מרכז המסגרת ביחס למשבצת, הגובה והרוחב של המסגרת, ורמת ה-objectness, כפי שהוסברה לעיל. בנוסף, כל מסגרת מבצעת גם סיווג, כלומר מנבאת את רמת הוודאות של השתייכות האובייקט לכל אחת מהמחלקות האפשריות. החידוש באלגוריתם נעוץ בעובדה שחיוזי המסגרות וסיווגן לאובייקטים נעשה במקביל, ולא באופן דו-שלבי. הרעיון הוא להתייחס לסוג האובייקט כעוד פיצ'ר שהרשת מנסה לחזות בנוסף למיקום וגודל של המסגרת.

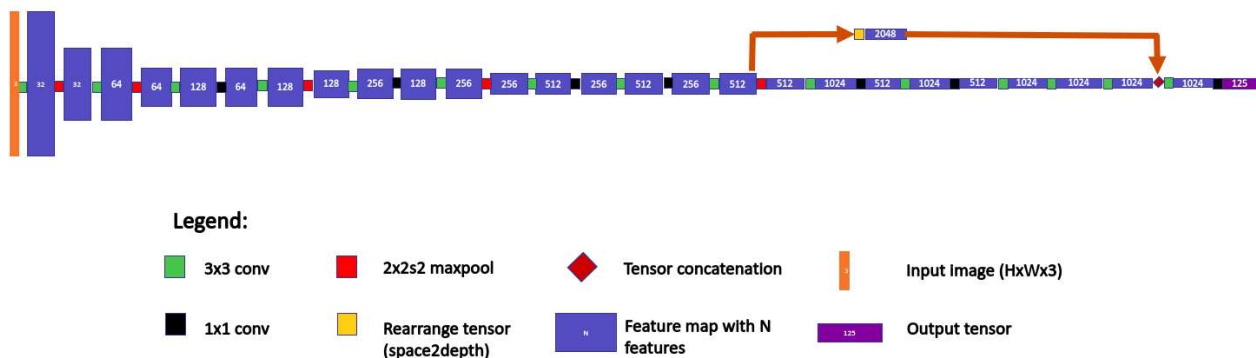


איור 9.3 ארכיטקטורת YOLO.

הגרסה הראשונה של ארכיטקטורת YOLO כללה שכבת fully connected שהוסרה בגרסאות הבאות. בנוסף, פונקציית ה-LOSS וסדר התכונות של המסגרות במוצא הרשת השתנו, אבל הרעיון נותר זהה.

## YOLOv2

גרסה זו משתמשת ברשת Backbone הנקראת Darknet19 ובה 19 קונבולוציות. המודל כולו כולל 22 קונבולוציות (מלבד 5 שכבות ה-MAXPOOL המקובלות על מנת למצוא את הפיצ'רים), ועוד מסלול עוקף בסמוך לסוף הרשת המחזק את יכולת העיבוד. הכותב של המאמר המקורי, רדמון, נהג לפתח גם גרסאות "Tiny" לכל מודל. הווריאנט YOLOv2 Tiny מכיל רשת Backbone קצרה יותר וללא מסלול עוקף ומבנה לינארי ופשוט מאוד. ביצועיו אמנם נמוכים יותר אך הוא מהיר מאוד (207 תמונות לשנייה לעומת 67 של מודל YOLOv2, על מעבד TitanX). מעניין לציין ש-YOLOv2 הוא המודל הראשון שאומן על תמונות בממדים משתנים, תהליך המשפר את דיוק המודל.




איור 9.4 ארכיטקטורת YOLOv2.

## YOLOv3

כל דור נוסף של YOLO הציג חידושים ארכיטקטוניים שהגדילו את מורכבות החישוב וגודל המודל ושיפרו את ביצועיו. גרסה מספר 3 מבוססת על רשת Backbone גדולה בהרבה שנקראת Darknet53 ובה, כפי שעולה משמה, 53 קונבולוציות. כמו כן הרשת מכילה צוואר של ארכיטקטורת Feature Pyramid Network (FPN) בעלת שלושה ראשי גילוי, כאשר כל אחד מהם הוא בעל רזולוציה שונה ( $19 \times 19$  ו- $76 \times 76$ ).

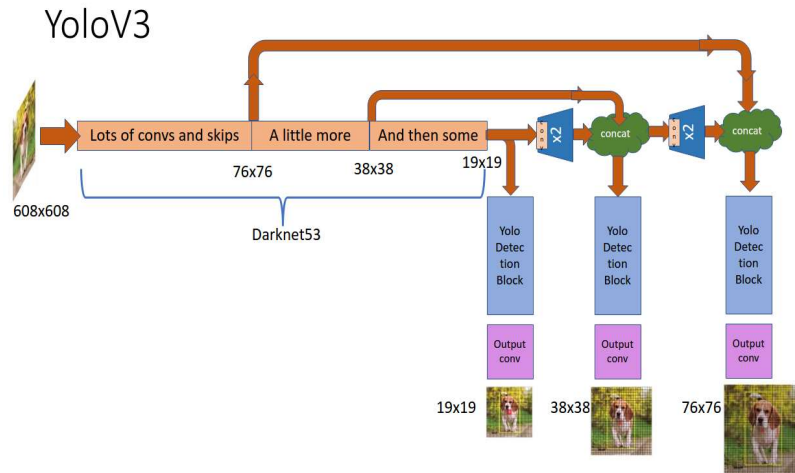
ארכיטקטורת FPN היא תוספת בקצה ה-Backbone, אשר מגדילה חזרה באופן הדרגתי את מפת הפיצ'רים. תוספת זו נועדה ליצור מסלול Top Down במקביל למסלול ה-Feed Forward ברשת ה-Backbone, שבנוי למעשה בצורת Bottom Up, בו ככל שמתקדמים בשכבות ה-Backbone מתבצע עיבוד ברמה גבוהה יותר והרזולוציה המרחבית של מפת הפיצ'רים הולכת וקטנה. בעזרת השימוש ברשת ה-FPN המודל לומד לנצל את המיטב משני עולמות: הוא משתמש במידע שטמון במפת הפיצ'רים הגדולה, שהיא אמנם פחות מעובדת אך בעלת פיצ'רים ברזולוציה מרחבית גבוהה, ובנוסף הוא מנצל גם את המידע ממפת הפיצ'רים הקטנה, שהיא אמנם בעלת פיצ'רים ברזולוציה מרחבית נמוכה, אך עם זאת היא מעובדת יותר.

לאחר כל הגדלה של מפת הפיצ'רים מתבצע חיבור בין התוצאה לבין מפת פיצ'רים קדומה יותר בממדים זהים (מתוך ה-Backbone). זאת בדומה לחיבורים העקיפים ברשת ResNet המסייעים להתכנסות האימון. השכבות השונות של רשת FPN מאפשרות לגלאי למצוא מיקום מדויק יותר של האובייקט ברזולוציות השונות, מה שמעניק לרשת זו את היכולת להבחין באובייקטים קטנים בתמונה גדולה.



איור 9.5 ארכיטקטורת Feature Pyramid Network (FPN), המשלבת מסלול top down לאחר ה-bottom up.

לראש המודל של YOLOv3 יש מספר ענפי detection, אשר כל אחד מהם פועל על מפת פיצ'רים ברזולוציה שונה ובאופן טבעי מתמחה בגילוי אובייקטים בגודל שונה (הענף בעל הרזולוציה הנמוכה מתמחה בגילוי אובייקטים גדולים, והענף בעל הרזולוציה הגבוהה מתמחה בגילוי אובייקטים קטנים).



איור 9.6 ארכיטקטורת YOLOv3.

## YOLOv4

רשת YOLOv4 היא בעלת ראש זהה לזה של שתי הגרסאות הקודמות, אך ה-Backbone שונה ומורכב יותר. הוא נקרא CSPDarknet53 כאשר CSPNET היא קיצור של Cross-Stage Partial Network. רשת זו מפצלת מפות פיצ'רים לטובת קונבולוציה בחלקים ואיחוד מחדש. פיצול זה מאפשר, כמוזכר במאמר המקורי, חלחול טוב יותר של הגרדיאנטים בשלב האימון. בנוסף, נעשה ברשת זו שימוש בפונקציית אקטיבציה הנקראת Mish (ולא Leaky ReLU כמו בגרסאות הקודמות).

אנקדוטה מעניינת – החל מגרסה זו התצורות אינן של היוצר המקורי ג'וזף רדמון, שהחליט לפרוש ממחקר ראייה ממוחשבת בגלל שיקולים אתיים של שימושים צבאיים או שימושים הפוגעים בפרטיות.

## YOLOv5

רשת YOLOv5 מוסיפה עוד שכלולים על רשת ה-Backbone על פניו של הדור הקודם, ומציגה אופרטור חדש המארגן פיקסלים סמוכים בתמונת במימד הפיצ'רים. אופרטור זה דואג לכך שהכניסה לרשת היא לא בעומק 3 פיצ'רים כמקובל (RGB), אלא 12 פיצ'רים, תוך הקטנת המימד המרחבי. באופן זה הרשת מתאמנת לעבד תמונות ברזולוציה גבוהה, ואף לזהות אובייקטים גדולים בקלות רבה יותר, שכן שדה התמך (receptive field) של הקונבולוציות מכיל מידע משטח תמונה גדול יותר.

### 9.1.4 Spatial Pyramid Pooling (SPP-net)

Spatial Pyramid Pooling (SPP) הינה שכבת pooling ברשת נוירונים, שמטרתה להסיר את האילוף של רשתות קונבולוציה, הדורש ששכבת הכניסה לרשת תכיל תמונה בגודל קבוע (כמו למשל רשת VGG, המקבלת רק תמונות בגודל  $224 \times 224$ ).

כיום קיימים מכשירי צילום רבים – החל ממצלמות ניידות, מקצועיות, מצלמות אבטחה ואף מצלמות בטלפונים סלולריים ורחפנים. מצלמות שונות עשויות להוציא כפלט תמונות בגדלים שונים, ממגוון סיבות (למשל איכות התמונה או מטרת המכשיר). אם נרצה לבצע סיווג באותה רשת נוירונים לכל אותן תמונות, נאלץ לבצע שלב נוסף בתחילת הדרך – התאמת התמונה בכניסה לרשת.


נשים לב כי על מנת להתאים תמונה כלשהי לגודל מסוים, לרוב יבוצע חיתוך (crop), או שינוי גודל (resize/wrap). פעולות אלה עלולות לפגוע בזיהוי עקב שינוי היחס בתמונה (מתיחה/כיווץ), החסרה של פרטים או שילוב של השניים. מוטיבציה זו היא שהובילה לשימוש בטכניקת SPP.

ניתן לראות דוגמה לשינוי גודל באמצעות מתיחה ולחיתוך באיור הבא:



למעשה, הדרישה לתמונת קלט בגודל קבוע בכניסה לרשתות אלה אינה הכרחית, שכן שכבות הקונבולוציה יכולות לחלץ מאפייני קלט (feature maps) בכל גודל. לעומתן, שכבות ה-FC בעומק הרשת הן השכבות שדורשות בכניסה להן קלט בגודל קבוע.

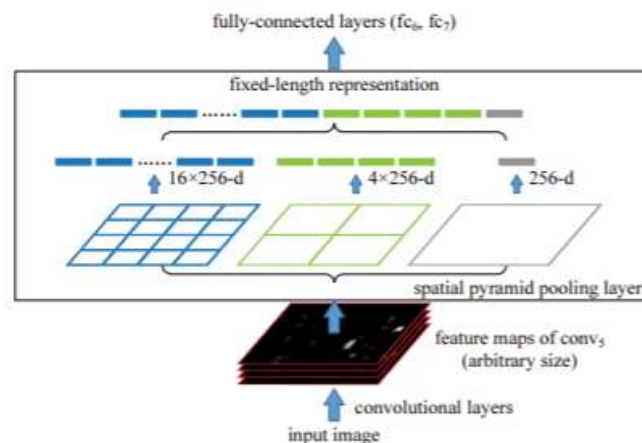
כעת, לאחר שהובהרה המוטיבציה ליצירת רשת זו, ניתן להבין את אופן פעולתה. על בסיס שכבת ה-SPP מתבססת רשת SPP-Net. החידוש במבנה הרשת, הוא שבמקום שבכניסה לרשת (לפני שכבות הקונבולוציה) תבוצע התאמת תמונת הקלט לגודל הנדרש ברשת. ההתאמה המבוצעת בשכבת SPP תבוצע לאחר מציאת המאפיינים בשכבות הקונבולוציה, אך לפני שכבת ה-FC, כמתואר באיור הבא:



איור 9.8 – מבנה של רשת CNN קלאסית (למעלה) לעומת מבנה של רשת SPP-Net (למטה).

הרעיון מאחורי שכבת SPP הוא חלוקה של הפלט של שכבות הקונבולוציה, ביצוע max-pooling בכל חלק ושרשור של התוצאות לווקטור שגודלו אחיד. במילים אחרות, עבור כל ה-feature maps המתקבלים לאחר שכבות הקונבולוציה, מייצרים שלושה וקטורים לכל feature:

- וקטור בגודל 1 המתקבל באמצעות ביצוע max-pooling על כל הערכים באותו ה-feature.
  - חלוקה של ה-feature ל-4 תת-חלקים  $(2 \times 2)$  וביצוע max-pooling בכל חלק מתוכם. מתקבל וקטור בגודל 4.
  - חלוקה של ה-feature maps ל-16 תת-חלקים  $(4 \times 4)$  וביצוע max-pooling בכל חלק מתוכם. מתקבל וקטור בגודל 16.
  - שרשור כל הווקטורים יחד לווקטור בעל 21 ערכים.
  - בסיום התהליך, תתקבל שכבה בייצוג אחיד בגודל 21, בהכפלה במספר ה-features שהתקבלו משכבות הקונבולוציה. שכבה זו "מחליפה" את שכבת ה-pooling הממוקמת לאחר שכבת הקונבולוציה האחרונה ותוצרה הוא הקלט לשכבת ה-FC.
- ניתן לראות את מבנה הרשת באיור הבא, בו התקבלו 256 features:



איור 9.9: ארכיטקטורת SPP-Net.

## 9.2 Segmentation

אחד האתגרים הכי משמעותיים בעולם הראייה הממוחשבת הוא זיהוי אובייקטים בתמונה והבנת המתרחש בה. אחת הטכניקות הקלאסיות להתמודדות עם משימה זו הינה ביצוע סגמנטציה, כלומר, התאמת label לכל פיקסל בתמונה. בתהליך הסגמנטציה מבצעים חלוקה/בידול בין עצמים שונים בתמונה המצולמת באמצעות סיווג ברמת הפיקסל, כלומר כל פיקסל בתמונה יסווג וישויך למחלקה מסוימת.

ישנם שימושים מגוונים באלגוריתמים של סגמנטציה – הפרדה של עצמים מסוימים מהרקע שמאחוריהם, מציאת קשרים בין עצמים ועוד. לדוגמא, תוכנות של שיחות ועידה, כמו zoom, skype, teams וכדו', מאפשרות בחירת רקעים שונים עבור המשתמש, כאשר מלבד הרקע הנבחר רק הגוף של המשתתף מוצג בווידאו. הפרדת גוף האדם מהרקע והטמעת רקע אחר מתבצעות באמצעות אלגוריתמים של סגמנטציה. דוגמא נוספת – ניתן לזהות בתמונה אדם, כלב, וביניהם רצועה, ומכך ניתן להסיק שתוכן התמונה הוא אדם מחזיק כלב בעזרת רצועה. במקרה זה, הסגמנטציה נועדה למצוא קשר בין עצמים ולהבין את המתרחש.

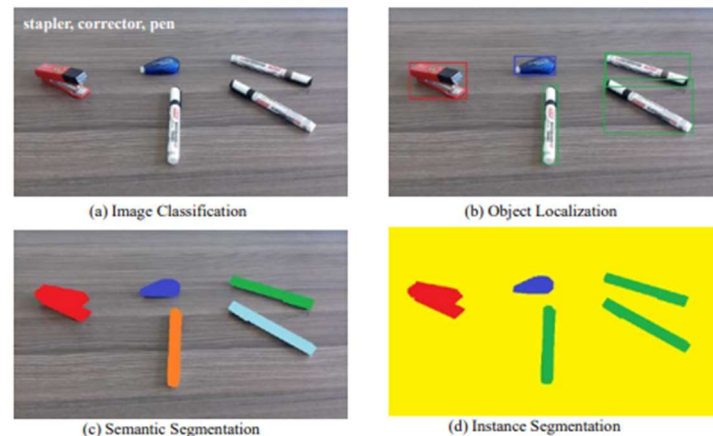
### 9.2.1 Semantic Segmentation vs. Instance Segmentation

קיימים שני סוגים עיקריים של סגמנטציה:

**Semantic segmentation** (חלוקה סמנטית) - חלוקה של כל פיקסל בתמונה למחלקה אליה העצם אותו הוא מייצג שייך. למשל, פיקסל יכול להיות משויך לכלי רכב, בן אנוש, מבנה וכדו'.

**Instance segmentation** (חלוקה מופעית) - חלוקה של פיקסל בתמונה למופע של אותה מחלקה אליה העצם אותו הוא מייצג שייך. במקרה זה, בתמונה בה מופיעים מספר כלי רכב, תבוצע חלוקה של כל פיקסל לאיזה כלי רכב אותו פיקסל מייצג – מכונית 1, מכונית 2, אופנוע 1, משאית 1 וכדו'.

ההבדל העיקרי בין שני סוגים אלו הוא ברמת עומק המיפוי של פיקסל - המיפוי עשוי לסווג את הפיקסל למחלקה כלשהי, או לעצם ספציפי בתמונה. עומק המיפוי משליך גם על עלות המיפוי. החלוקה הסמנטית מבוצעת ישירות, בעוד שהחלוקה המופעית דורשת בנוסף ביצוע של זיהוי אובייקטים כדי לסווג מופעים שונים של המחלקות.




איור 9.7 משימות שונות תחת התחום של Computer Vision. ניתן להבחין בהבדל שבין Semantic segmentation (התאמת כל פיקסל למחלקה מסוימת) לבין Instance segmentation (התאמת כל פיקסל למופע של מחלקה מסוימת).

### 9.2.2 SegNet neural network

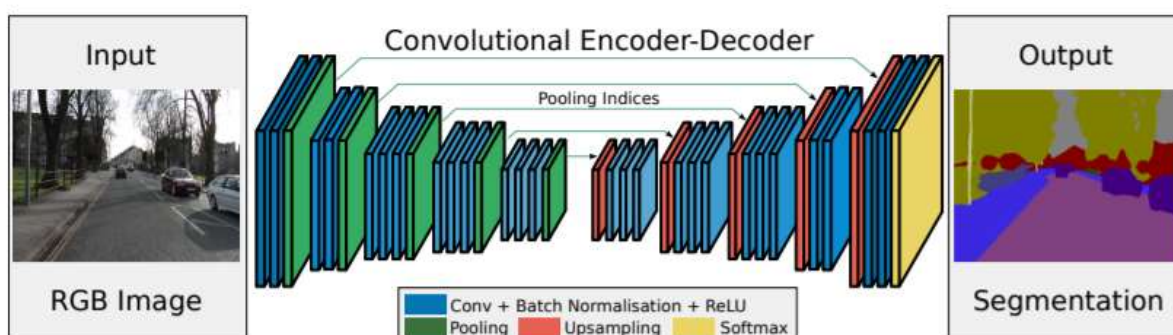
רשת SegNet הינה רשת קונבולוציה עמוקה, שמטרתה לבצע חלוקה סמנטית (Semantic segmentation) לתמונת הקלט. בתחילה הרשת פותחה להבנה של תמונות חוץ (למשל כביש עם מכוניות ובצדדים בתים והולכי רגל) ותמונות פנים (למשל חדר עם מיטה וכיסאות). הרשת נבנתה מתוך מטרה להיות יעילה בהיבטי זיכרון וזמן חישוב, תוך שמירה על דיוק מעשי.





איור 9.7 סיווג סמנטי בעזרת רשת SegNet עבור תמונות פנים וחוץ.


הרשת בנויה כארכיטקטורת מקודד-מפענח (encoder-decoder). המקודד מורכב מ-13 השכבות הראשונות של רשת VGG16, ומטרתו לחלץ את מפת המאפיינים (feature maps). לכל שכבת קידוד יש שכבת פיענוח תואמת ומכאן שגם רשת המפענח מכילה 13 שכבות. מטרת המפענח היא לבצע up-sampling ולייצר תמונת מאפיינים בגודל המקורי. את מוצא המפענח מעבירים דרך מסווג SoftMax, המתאים את המחלקה בעלת ההסתברות הגבוהה ביותר לכל פיקסל בנפרד.



איור 9.8 ארכיטקטורת רשת SegNet.

המקודד מורכב משכבות קונבולוציה, אחריהן שכבות נרמול (batch normalization) ושכבות אקטיבציה מסוג ReLU. לאחר שכבות אלו, ישנה שכבת max-pooling המבצעת subsampling, בעלת גודל חלון  $2 \times 2$  ומרווח (stride) בגודל 2.

החידוש ברשת זו הוא אופן הפעולה של המפענח. בשונה מרשתות אחרות, בהן תהליך ה-up-sampling גורר ביצוע חישובים עבור הפיענוח, כמתואר באיור הבא, הרעיון ברשת זו הוא שמירת מיקומי ערכי המקסימום הנבחרים מכל רביעייה. רק הערכים שנבחרו כמקסימום ישוחררו בתהליך ושאר הערכים יתאפסו.



איור 9.9 שכבת פענוח ברשת לעומת רשת FCN.

ארכיטקטורה זו מביאה את הרשת לביצועים טובים בהיבטי זמן חישוב, על חשבון פגיעה מסוימת בדיוק הרשת. למרות זאת, ביצועי הרשת מתאימים לשימושים פרקטיים והפגיעה בדיוק קטנה מאוד.

בדומה למקודד, לאחר כל שכבת up-sampling במפענח, יופיעו שכבות קונבולוציה, שכבות נרמול ושכבות אקטיבציה מסוג ReLU. את מוצא המפענח מעבירים דרך שכבת SoftMax המבצעת סיווג ברמת הפיקסל. מוצא הרשת, שהוא גם מוצא שכבת ה-SoftMax, הינו מטריצת הסתברויות, כאשר עבור כל פיקסל יש וקטור באורך  $K$ , כאשר  $K$  הוא מספר המחלקות לסיווג. כמובן שהסיווג מתבצע בהתאמה להסתברות הגבוהה ביותר המתאימה לכל פיקסל.

אימון הרשת בוצע על בסיס מידע קטן יחסית של 600 תמונות דרך צבעוניות בגודל  $360 \times 480$ , שנלקחו מבסיס המידע CamVid road scene dataset. סט האימון הכיל 367 תמונות וסט הבדיקה הכיל את 233 התמונות הנותרות. המטרה הייתה לזהות בתמונות אלה 11 מחלקות (דרך, בניין, מכונית, הולכי רגל וכדומה). כל תמונה עברה נרמול מקומי לערך הניגודיות של תמונת הקלט לפני הכניסה לרשת. האימון בוצע בשיטת ה-SGD, עם קצב למידה קבוע שערכו 0.1 ומומנטום שערכו 0.9. האימון נמשך עד ששיגאת האימון התכנסה. לפני כל epoch סט האימון עורבב וחולק ל-mini-batch של 12 תמונות. פונקציית המחיר הינה cross-entropy.

לעיתים, נדרש לבצע איזון-מחלקות (class balancing). מונח זה מתאר מצב בו קיים שוני גדול בין כמות הפיקסלים המשויכים לכל מחלקה, למשל כאשר קיימת הטיה מסוימת - סצינה שברובה מכילה בניינים / דרכים. במצב זה, יבוצע משקול מחודש לפונקציית השיגאה, באמצעות תהליך "איזון התדירות החציונית" (median frequency balancing). התהליך ממשקל מחדש את המחלקות בפונקציית המחיר, באופן יחסי לחציון של תדירות הופעות המחלקות בכל סט האימון, תוך חלוקה בתדירות הופעת המחלקה:

$$\alpha_c = \frac{\text{median freq}}{\text{freq}(c)}$$

משקול זה משנה את היחסים בפונקציית המחיר כך שהתרומה של כל המחלקות לפונקציית המחיר תהיה שווה. לכן, הוא מעניק למחלקות הגדולות יותר משקל נמוך יותר ולמחלקות הקטנות משקל גבוה יותר.

### 9.2.3 Atrous Convolutions (Dilated Convolutions)

המונח Atrous מקורו בשפה הצרפתית – "à trous", שמשמעו "עם חורים". לכן, ניתן לתרגם את המונח Atrous convolution כ-"קונבולוציה מחוררת", ובמשמעות מעט יותר מתאימה – קונבולוציה מרווחת (או בשם אחר – Dilated convolution – קונבולוציה מורחבת).


בטכניקת קונבולוציה זו, יש שימוש בפרמטר נוסף בנוסחת הקונבולוציה – dilation rate. פרמטר זה מסמן את המרווח בין כל איבר בגרעין הקונבולוציה (הרחבה על פרמטר זה – בפרק 5.1.2). נוסחת הקונבולוציה עבור המקרה החד מימדי יחד עם פרמטר ההתרחבות  $r$  ניתנת לתיאור באופן הבא:

$$y[i] = \sum_{k=1}^K x[i + r \cdot k]w[k]$$



עבור  $r = 1$  מתקבלת הקונבולוציה הרגילה, וכאשר ישנו dilation של  $r > 1$ , מתקבלת קונבולוציה מרווחת בפקטור  $r$ . יתרונה של קונבולוציה נעוץ בכך שעבור אותו קרנל ועבור אותה כמות חישובים, מרחיבים את ה-field of view (FoV) של הקונבולוציה.

ניתן לראות את הרחבת ה-field of view באיור הבא:



איור 9.10: קונבולוציה מרווחת דו-מימדית, עם קרנל בגודל  $3 \times 3$  ופרמטר התרחבות  $r = 1, 6, 24$ . בהתאם לכל פרמטר מתקבל field-of-view בגודל שונה –  $3 \times 3$ ,  $16 \times 16$ ,  $49 \times 49$  בהתאמה.

## 9.3 Face Recognition and Pose Estimation

### 9.3.1 Face Recognition

אחד מהיישומים החשובים בראייה ממוחשבת הינו זיהוי פנים, כאשר ניתן לחלק משימה זו לשלושה שלבים:

1. Detection – מציאת הפרצופים בתמונה.
2. Embedding – מיפוי כל פרצוף למרחב חדש, בו המאפיינים שאינם קשורים לתיאור הפנים (למשל: זווית, מיקום, תאורה וכדו') אינם משפיעים על הייצוג.
3. Searching – חיפוש במאגר של תמונות למציאת תמונת פנים הקרובה לתמונת הפנים שחולצה מהתמונה המקורית.

גישה פשטנית, כמו למשל בניית מסווג המכיל מספר יציאות כמספר הפנים אותם רוצים לזהות, הינה בעייתית משתי סיבות עיקריות: ראשית יש צורך באלפי דוגמאות לכל אדם (שלא ניתן בהכרח להשיג). כמו כן, נצטרך ללמד את המערכת מחדש בכל פעם שרוצים להוסיף מישור חדש. כדי להתגבר על בעיות אלו מבצעים "למידת מטריקה" (metric learning) בה מזקקים מאפיינים של פנים ויוצרים וקטור יחסית קצר, למשל באורך 128, המכיל את האלמנטים המרכזיים בתמונת הפנים. כעת נפרט את שלושת השלבים:


#### 1. מציאת פנים.

כדי למצוא פרצופים בתמונה ניתן להשתמש ברשתות המבצעות detection, כפי שתואר בפרק 9.1. שיטה מקובלת למשימה זו הינה Yolo, המבוססת על חלוקת התמונה למשבצות, כאשר עבור כל משבצת בוחנים האם יש בה אובייקט מסוים, מהו אותו אובייקט, ומה ה-bounding box שלו.

#### 2. תיאור פנים.

כאמור, המשימה בתיאור פנים נעשית בעזרת metric learning, כאשר הרעיון הוא לזקק פנים לוקטור שאינו מושפע ממאפיינים שלא שייכים באופן מהותי לפנים הספציפיות האלה, כגון זווית צילום, רמת תאורה וכדו'. בכדי לעשות זאת יש לבנות רשת המקבלת פנים של בנאדם ומחזירה וקטור, כאשר הדרישה היא שעבור שתי תמונות של אותו אדם יתקבלו וקטורים מאוד דומים, ועבור פרצופים של אנשים שונים יתקבלו וקטורים שונים. למעשה, פונקציית ה-loss תקבל בכל פעם minibatch, ותעניש בהתאם לקרבה בין וקטורים של אנשים שונים וריחוק בין וקטורים של אותו אדם.

כעת נניח שיש לנו קלט  $X$ , המכיל אוסף פרצופים. כל איש יסומן באות אחרת – A,B,C, ותמונות שונות של אותו אדם יסומנו על ידי אות ומספר, כך שלמשל  $X_{A1}$  זוהי התמונה הראשונה של אדם A בסט הקלט  $X$ , וכמובן ש- $X_{A1}$  ו- $X_{A2}$  הן שתי תמונות של אותו אדם. באופן גרפי, בדו-ממד ניתן לתאר זאת כך (בפועל הווקטורים המייצגים פנים יהיו בממד גבוה יותר):



איור 9.10 (a) דוגמאות מסט הפרצופים  $X$ . (b) איך נרצה שהדאטה ימופה לממד חדש  $Y$ .

כאמור, נרצה לבנות פונקציית loss שמעודדת קירבה בין  $X_{A1}$  ו- $X_{A2}$ , וריחוק בין  $X_{B1}$  ו- $X_{A1}$ . פונקציית ה-loss מורכבת משני איברים, המודדים מרחק אוקלידי בין וקטורים שונים:

$$L = \sum_X \|Y(X^{Ai}) - Y(X^{Aj})\| - \|Y(X^{Ai}) - Y(X^{Bj})\|$$


כאשר האיבר הראשון ינסה להביא למינימום וקטורים של אותו אדם, והאיבר השני ינסה להביא למקסימום וקטורים של פרצופים שאינם שייכים לאותו אדם. כיוון שנרצה להימנע מקבלת ערכים שליליים, נוסיף פונקציית מקסימום. בנוסף, ניתן 'להרחיק' תוצאות של פרצופים שונים על ידי הוספת קבוע  $k$ , כך שהפרש בין המרחק של פרצופים של אנשים שונים לבין המרחק של פרצופים של אותו איש יהיה לפחות  $k$ :

$$L = \sum_X \max(\|Y(X^{Ai}) - Y(X^{Aj})\| - \|Y(X^{Ai}) - Y(X^{Bj})\| + k, 0)$$

loss כזה נקרא triplet loss, כיוון שיש לו שלושה איברי קלט – שתי תמונות של אותו אדם ואחת של מישהו אחר. כאמור, הפלט של הרשת הנלמדת צריך להיות וקטור המאפיין פנים של אדם, ומטרת הרשת היא למפות פרצופים שונים של אותו אדם לווקטורים דומים עד כמה שניתן, ואילו פרצופים של אנשים שונים יקבלו וקטורים רחוקים זה מזה.

### 3. מציאת האדם

בשלב הקודם, בו התבצע האימון, יצרנו למעשה מאגר של פרצופים במרחב חדש. כעת כשיגיע פרצוף חדש, כל שנתר זה למפות אותו למרחב החדש, ולחפש במרחב זה את הווקטור הקרוב ביותר לווקטור המייצג את הפנים החדשות. בכדי לעשות זאת ניתן להשתמש בשיטות קלאסיות של machine learning, כמו למשל חיפוש שכן קרוב (כפי שהוסבר בחלק 2.1.3). שיטות אלו יכולות להיות איטיות עבור מאגרים המכילים מיליוני וקטורים, וישנן שיטות חיפוש מהירות יותר (ובדרך כלל המהירות באה על חשבון הדיוק). בעזרת השיטה המובילה כרגע (SCANN) ניתן להגיע לכמה מאות חיפושים שלמים בשנייה (החיפוש ב-100 ממדים מתוך מאגר של 10000 דוגמות).



איור 9.11 השוואת ביצועים של שיטות חיפוש שונות. עבור פרצוף נתון, מחפשים עבורו וקטור תואם בממד החדש המכיל ייצוג וקטורי של הפרצופים הידועים. בכל שיטה יש טרייד-אוף בין מהירות החיפוש לבין הדיוק.


מלבד זיהוי וסיווג פנים, יש גם שיטות של מציאת אלמנטים של פנים הכוללות אף, עיניים וכו'. אחת השיטות המקובלות משתמשת בשערוך הצורה של פנים אנושיות, וניסיון למצוא את איברי הפנים לפי הצורה הסטנדרטית. בשיטה זו ראשית מבצעים יישור של הפנים והתאמה לסקאלה אנושית (על פי מרחק בין האיברים השונים בפנים), ולאחר מכן מטילים 68 נקודות עניין מרכזיות על התמונה המיושרת, מתוך ניסיון להתאים בין הצורה הידועה לבין התמונה המבוקשת.



איור 9.12 זיהוי אזורים בפנים של אדם על ידי התאמת פנים לסקאלה אנושית והשוואה למבנה של פנים המכיל 68 נקודות מרכזיות.

### 9.3.2 Pose Estimation

יישום פופולרי נוסף של אלגוריתמים השייכים לראייה ממוחשבת הינו קביעת תנוחה של אדם – האם הוא עומד או יושב, מה התנוחה שלו, באיזה זווית האיברים נמצאים וכו'. ניתן להשתמש בניתוח התנוחה עבור מגוון תחומים – ספורט, פיזיותרפיה, משחקים שונים ועוד. לרוב, תנוחה מיוצגת על ידי המיקומים של חלקי גוף עיקריים כגון ראש, כתפיים, מרפקים וכו'. ישנם כמה סטנדרטים מקובלים, למשל COCO, COCO pose net ועוד. ב-COCO התנוחה מיוצגת בעזרת מערך של 17 נקודות (בדו-מימד):



איור 9.13 מיפוי תנוחה ל-17 נקודות מרכזיות.

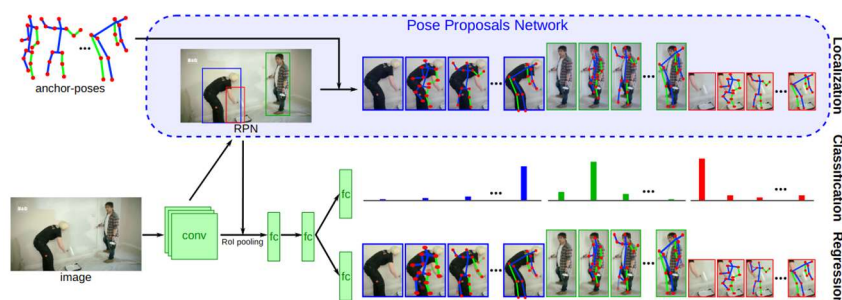
שאר הפורמטים דומים; מוסיפים עוד מידע (למשל מיקום הפה), משתמשים בתלת ממד במקום בדו ממד, משתמשים בסידור אחר וכדו'. כאשר רוצים לאסוף נתונים על מנחי גוף שונים, ניתן לשים חיישנים על אותן נקודות מרכזיות וככה לקבל מידע על מנח הגוף לאורך זמן.

רשת לצורך קביעת תנוחה יכולה לטפל במקרה כללי, בו יש מספר אנשים בתמונה, או במקרה הפרטי של גוף יחיד. המקרה השני כמובן יותר פשוט, מכיוון שישנו פלט יחיד, אותו ניתן לחזות באמצעות רגרסיה (למשל, 34 מספרים שמתארים את המיקומים של 17 הנקודות בפורמט COCO בדו-ממד). במקרה זה ניתן לעשות למידה סטנדרטית לחלוטין של בעיית רגרסיה בעלת 34 יציאות.

ישנן מספר גישות כיצד להכליל את הרשת כך שתוכל לטפל גם במקרה הכללי בו יש יותר מגוף אחד בתמונה. באופן נאיבי ניתן לבצע תהליך מקדים של מציאת כל האנשים בתמונה, ואז להפעיל על כל אחד מהם בנפרד את הרשת שמבצעת רגרסיה, כפי שתואר לעיל. שיטה נוספת פועלת בכיוון הפוך – ראשית כל הרשת מוצאת את כל האיברים בתמונה נתונה, ולאחר מכן משייכת אותם לאנשים שונים. השיטה השנייה נקראת "מלמטה למעלה" (bottom-up), כיוון שקודם כל היא מוצאת את הפרטים ולאחר מכן מכלילה אותם. גישה זו יעילה למקרה בו יש הרבה חפיפה בין האנשים בתמונה, כיוון שאין לה צורך לבצע תהליך מקדים של הפרדת האנשים. השיטה הראשונה, הנקראת "מלמעלה למטה" (top-down), תהיה פשוטה יותר עבור מקרים בהם אין חפיפה בין האנשים בתמונה וכל אחד מהם נמצא באזור שונה בתמונה, כיוון שבמקרה זה אין צורך לשייך איברים לאנשים.

רשת פופולרית לקביעת תנוחה נקראת Multi-person pose estimation, המורכבת למעשה משתי תת-רשתות ופועלת בשיטת bottom-up. הרשת שאחראית על שיוך חלקי גוף לאדם מסוים, נקראת part affinity fields (PAF), והרעיון שלה הוא לייצג כל איבר כשדה וקטורי. בייצוג זה הווקטורים השונים מצביעים לכיוון איבר הגוף ה'בא בתור' (למשל זרוע מצביעה ליד), וככה ניתן לשייך איברים שונים אחד לשני, ואת כל יחד לגוף מסוים.

רשת פופולרית אחרת, הפועלת בגישת top-down, נקראת LCR-NET, והיא מבוססת על רעיון של 'מיקום-סיווג-רגרסיה' (Localization-Classification-Regression). בשלב הראשון יש תת-רשת המייצרת עוגנים עבור אנשים, כלומר, אזורים בהם הרשת חושבת שנמצא בן אדם, ולאחר מכן הרשת משערכת את התנוחות שלהם. בשלב השני מתבצע clustering לכל העוגנים, כלומר כל עוגן מקבל ציון המייצג את טיב השערוך של העוגן והתנוחה של האדם הנמצא בתוכו. השלב השלישי מלטש את העוגנים ומשקלל את השערוך הסופי בעזרת מיצוע של הרבה עוגנים. שלושת השלבים משתמשים ברשת קונבולוציה משותפת, כמתואר באיור.



איור 9.14 Localization-Classification-Regression.

## 9.5 Few-Shot Learning

יכולת הצלחתם של אלגוריתמי למידה עמוקה נשענת על כמות ואיכות הדאטה לאימון. עבור משימת סיווג תמונות (Image Classification), נדרש שעבור כל קטגוריית סיווג תהיה כמות גדולה של תמונות מגוונות (עם הבדלי רקעים, בהירות, זוויות וכו'), ובנוסף יש צורך בכמות דומה של דוגמאות בכל קטגוריות הסיווג. חוסר איזון בין כמות התמונות בקטגוריות השונות משפיע על יכולת הלמידה של האלגוריתם את הקטגוריות השונות ועל כן עלול ליצור הטיה בתוצאות הסיווג לטובת הקטגוריות להן יש יותר דוגמאות. בפרק זה נעסוק בשיטות כיצד ניתן להתמודד עם מצבים בהם הדאטה אינו מאוזן.

### 9.5.1 The Problem

התחום של למידה ממיעוט דוגמאות (Few-Shot Learning) נוצר על מנת להתמודד עם מצב של חוסר איזון קיצוני בין כמות הדוגמאות של כל קטגוריה לאימון הרשת. באופן פורמלי, קיימות קטגוריות הנקראות קטגוריות בסיס (base classes), עבורן יש כמות גדולה של דוגמאות, ובנוסף ישנן קטגוריות חדשניות (novel classes), עבורן יש כמות קטנה מאוד של דוגמאות. בכדי להגדיר את היחס, משתמשים בשני פרמטרים: פרמטר  $k$  המייצג את מספר ה-shots, כלומר מספר הדוגמאות הקיימות בסט האימון מכל קטגוריה חדשנית, ופרמטר  $n$  שמייצג את מספר הקטגוריות החדשניות הקיימות סך הכל. כל בעיה מוגדרת על ידי "k-shot n-way", ולמשל "one-shot 5-way learning" מתאר מצב בו יש חמש קטגוריות חדשניות, ומכל אחת מהן יש רק דוגמא אחת לאימון הרשת. ככלל, בקטגוריות הבסיס תהיה כמות גדולה של דוגמאות. למשל בסט התמונות האופייני לבעיות אלו, mini-ImageNet, יש 600 דוגמאות לכל קטגוריית בסיס ולרוב 1-5 דוגמאות עבור הקטגוריות החדשניות.

האתגר בלמידה ממיעוט דוגמאות נובע מהצורך להכניס לרשת כמות ידע קטנה נוספת על הידע הנרחב הקיים, תוך הימנעות מ-overfitting כתוצאה מכמות הפרמטרים הגדולה של הרשת לעומת הכמות המועטה של הדאטה. לכן, גישה נאיבית כמו אימון מחדש של רשת על מעט דוגמאות נוספות עלולה ליצור הטיה בתוצאות.

יש לציין כי בכל בעיות הלמידה ממיעוט דוגמאות, אמנם חסר דאטה עבור האימון, אך השאיפה היא להצליח באופן זהה בזיהוי כל הקטגוריות בשלב המבחן, בו לא יהיה חוסר איזון. לכן בעיות אלו רלוונטיות לשימושים רבים כמו: זיהוי חיות נדירות באופן זהה לחיות יותר נפוצות, מערכת זיהוי טילים שצריכה להתמודד גם עם איזמים נדירים יותר (ניתן לחשוב למשל על פצצת אטום), מערכות זיהוי פנים שצריכות לעבוד טוב עבור כל אדם ללא תלות בדאטה שהיה קיים באימון הרשת.


בפרק זה נתאר את שלוש הגישות העיקריות לפתרון בעיות למידה ממיעוט דוגמאות. עבור כל גישה נציג את האלגוריתמים המשמעותיים ביותר שנקטו בגישה זו. לאחרונה, מפותחים יותר ויותר אלגוריתמי למידה ממיעוט דוגמאות שמשלבים יחד רעיונות השאובים ממספר גישות יחד אך נשענים על האלגוריתמים המשמעותיים מהעבר. לבסוף, נציג את התחום של Zero-Shot Learning, כלומר יכולת למידה של קטגוריה חדשה כאשר לא קיימת אף דוגמא שלה לאימון.

### 9.5.2 Metric Learning

שיטות להתמודדות עם למידה ממיעוט דוגמאות הנוקטות בגישת למידת מטריקה, שואפות לייצג את הדוגמאות כווקטורים של מאפיינים במרחב רב-מימדי, כך שניתן יהיה למצוא בקלות את השיוך הקטגורי של דוגמא חדשה, גם אם היא תהיה מקטגוריה חדשנית. שיטות אלו מבוססות על עיקרון הגדלת המרחק בין ייצוגים וקטורים של דוגמאות מקטגוריות שונות (inter-class dissimilarity), בד בבד שמירה על מרחק קטן בין הייצוג הווקטורי של דוגמאות מאותה הקטגוריה (intra-class similarity).

התקדמות משמעותית של שיטות אלו הוצגה במאמר Matching Networks for One Shot Learning בשנת 2016. שיטה זו משתמשת בזיכרון שהגישה אליו נעשית באמצעות מנגנון Attention, על מנת לחשב את ההסתברות של דוגמא להיות שייכת לכל קטגוריה, בדומה לשיטות השכן הקרוב (Nearest Neighbors).






איור 9.15 אילוסטרציה של שיטת Matching Networks.


החידוש המשמעותי בשיטת Matching Networks נעוץ בשיטת האימון המבוצעת באפיזודות (Episodes). בשיטה זו האימון מכיל כמות של משימות, כאשר כל משימה היא למעשה מדגם של הדאטה שבו יש קטגוריות מסוימות שהן חדשניות ואחרות שהן קטגוריות בסיס. על ידי דגימות רבות ויצירת משימות מלאכותיות כאלו, בהן בכל פעם נלקחות קטגוריות אחרות לייצג את החדשניות, מתבצע אימון המתאים לבעיה של מיעוט דוגמאות. שיטת אימון באפיזודות הפכה לנפוצה ביותר בלמידה ממיעוט דוגמאות, גם בגישת המטריקה וגם בגישות שנראה בהמשך.

שיטות רבות מתבססות על הרעיונות של מאמר זה. למשל שיטת Relation Network משרשרת וקטורי מאפיינים של דוגמת מבחן לבין כל דוגמא של קטגוריות האימון. אלו נכנסים למודל המשערך מדד דמיון בעזרתו ניתן לסווג את דוגמת המבחן.



איור 9.16 Learning to Compare: Relation Network for Few-Shot Learning.

שיטה משמעותית נוספת הנוקטת בגישת למידת מטריקה נקראת Prototypical Networks. בגישה זו כל קבוצת דוגמאות של קטגוריה מסוימת במרחב וקטורי המאפיינים מקבלת נקודת אב-טיפוס אופיינית המחושבת על ידי הממוצע של הדוגמאות בקטגוריה זו. בכך מחשבים מסווג לינארי המפריד בין הקטגוריות. בעת המבחן נסווג דוגמא חדשה על סמך מרחק אוקלידי מנקודות האב-טיפוס.



איור 9.17 Prototypical Networks for Few-Shot Learning.

בטבלה הבאה ניתן לראות השוואת ביצועים של שיטות למידת המטריקה שהוזכרו על הקטגוריות החדשניות. יש להדגיש כי כל השיטות מגיעות לאחוזי דיוק נמוכים משמעותית מאחוזי הדיוק המדווחים במקרים של איזון בין כמות הדוגמאות בקטגוריות השונות (לרוב מעל 90% דיוק).

Method	5-way 1-Shot	5-way 5-Shot
Matching Networks	46.6%	60.0%
Prototypical Networks	49.42%	<b>68.20%</b>
Learning To Compare	<b>50.44%</b>	65.32%

איור 9.18 השוואת ביצועי דיוק של שיטות למידת מטריקה על קטגוריות חדשניות עבור mini-ImageNet.

### 9.5.3 Meta-Learning (Learning-to-Learn)

גישה שניה להתמודדות עם מיעוט דוגמאות וחוסר איזון בין הקטגוריות נקראת מטא-למידה (או: ללמוד איך ללמוד). באופן כללי בלמידת מכונה, כאשר מדובר על מטא-למידה, מתכוונים לרשת שלומדת על סמך התוצאות של רשת אחרת. בלמידה ממיעוט דוגמאות הרעיון הוא שהרשת תלמד בעצמה איך להתמודד עם מיעוט הדאטה על ידי עדכון הפרמטרים שלה לאופטימיזציה של בעיה של סיווג ממיעוט דוגמאות. לשם כך משתמשים באפיוזדות של משימות למידה ממיעוט דוגמאות.

שיטה חשובה בגישה זו היא Model-Agnostic Meta-Learning (MAML). בשיטה זו, שאינה מיועדת ספציפית לסיווג תמונות ממיעוט דוגמאות, בעזרת מספר צעדים מעטים בכיוון הגרדיאנט ניתן ללמד את הרשת התאמה מהירה (fast adaptation) למשימה חדשה. כזכור, כל משימה באימון היא אפיוזדה שבה קטגוריות מסוימות נבחרות רנדומלית לדמות את הקטגוריות החדשניות. בכל משימה כזו נלמדים פרמטרים של המודל האגנוסטי כך שעדכוןם בכיוון הגרדיאנט יוביל להתאמה למשימה החדשה. הכותבים מציינים שמנקודת מבט של מערכות דינאמיות, ניתן להתבונן על תהליך הלמידה שלהם ככזה שממקסם את רגישות פונקציית המחר של משימות חדשות ביחס לפרמטרים. כאשר הרגישות גבוהה, שינויי פרמטרים קטנים יכולים להוביל לשיפור משמעותי במחר של המשימה. מתמטית, פרמטרי המודל, המיוצגים על ידי  $\theta$ , משתנים עבור כל משימה  $T_i$  להיות  $\theta'_i$ , כאשר:


$$\theta'_i = \theta - \alpha \nabla_{\theta} L_{T_i}(f_{\theta})$$

עבור פונקציית מחר  $L$  והפרפרמטר  $\alpha$ . כאשר מבצעים מטא-למידה לעדכון הפרמטרים, מחשבים למעשה SGD:

$$\theta \leftarrow \theta - \beta \nabla_{\theta} \sum_{T_i \sim p(T)} (L_{T_i}(f_{\theta}))$$

כאשר המשימות נדגמות מתוך  $p(T)$  ו- $\beta$  הוא גודל הצעד של המטא-למידה.

שיטה מעניינת נוספת בשם Latent Embedding Classification (LEO) מיישמת את הגישה של מטא-למידה במרחב ייצוגי לטנטי בעל מימדים נמוכים, ולאחר מכן עובר בחזרה למרחב המאפיינים הרב מימדי.



איור 9.19 שיטת Latent Embedding Classification (LEO).

השימוש במרחב מאפיינים בעל מימדים נמוכים המשמרים את המאפיינים החשובים לייצוג הקטגוריות, שיפר באופן ניכר את תוצאות הסיווג, כפי שניתן לראות בטבלה הבאה:

Method	5-way 1-Shot	5-way 5-Shot
MAML	48.7%	63.11%
LEO	<b>61.76%</b>	<b>77.59%</b>

איור 9.20 השוואת ביצועי דיוק של שיטות מטא-למידה על קטגוריות חדשניות עבור mini-ImageNet.

#### 9.5.4 Data Augmentation

גישה שונה להתמודדות עם מיעוט דוגמאות נוקטת ביצירת דוגמאות כדי להימנע מהטיה. שיטות אוגמנטציה למעשה יוצרות דאטה חדש על סמך הדאטה הקיים. השיטות הפשוטות יותר מייצרות מהתמונות הקיימות תמונות ראי, שינויי תאורה וקונטרסט, שינויי סקאלה, שינויי זוויות, ואף הוספת רעש רנדומלי. כל אלו הראו שיפורים ביכולות הרשתות ללמוד קטגוריות שהיו במצב של חוסר איזון. דרך נוספת היא שימוש ברשתות גנרטיביות (GANs) על מנת לייצר דוגמאות רלוונטיות, למשל דוגמאות של אותו האובייקט מזוויות שונות. שיטה מעניינת של אוגמנטציות היא CutMix, בה פאצ'ים של תמונות נחתכים ומודבקים בתמונות האימון וגם התיוגים מעורבבים בהתאם. שיטה זו הגיעה לביצועים מרשימים בסיווג תמונות וגם בזיהוי אובייקטים, ככל הנראה בגלל שהיא מאפשרת למודל להיות גנרי יותר בהתייחסות לחלקים שונים מהתמונה המשפיעים על הסיווג לקטגוריה.

## 9. References

Detection:

<https://arxiv.org/pdf/1406.4729.pdf>

Segmentation:

<https://arxiv.org/ftp/arxiv/papers/2007/2007.00047.pdf>

SegNet:

<https://arxiv.org/pdf/1511.00561.pdf>

<https://mi.eng.cam.ac.uk/projects/segnet/#demo>

<https://arxiv.org/pdf/1409.1556.pdf>

<https://arxiv.org/pdf/1502.01852.pdf>

Face recognition:

[https://docs.opencv.org/master/d2/d42/tutorial\\_face\\_landmark\\_detection\\_in\\_an\\_image.html](https://docs.opencv.org/master/d2/d42/tutorial_face_landmark_detection_in_an_image.html)

<http://blog.dlib.net/2014/08/real-time-face-pose-estimation.html>