

לילה טוב חברים, היום אנחנו שוב בפינתנו DeepNightLearners עם סקירה של מאמר בתחום הלמידה העמוקה

היום בחרתי לסקירה את המאמר שנקרא Discriminator Rejection Sampling שיצא לפני קצת פחות כשנתיים. נכון שזה לא מאמר חדש אבל יש בו רעיון מגניב שאהבתי (:

תחום מאמר: GANs

מאמר הוצג בכנס: ICLR 2019

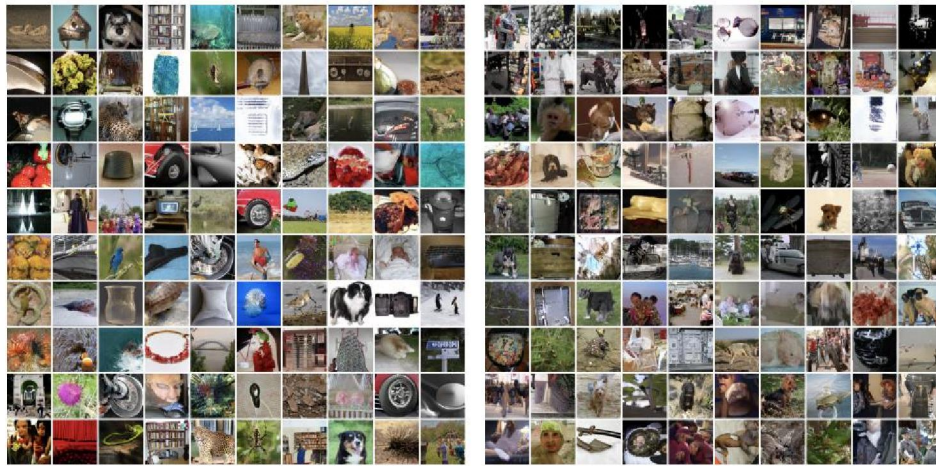


Figure 4: Synthesized images with the highest (left) and lowest (right) acceptance probability scores.

תמצית מאמר: המאמר מציע שיטה לשיפור איכות התמונות המגורטות ע"י GAN תוך כדי ניצול "ידע" שנצבר בדיסקרימינטור (D) במשך אימון של GAN. נזכיר ש D מאומן להבדיל בין תמונות מגורטות לתמונות אמיתיות כלומר פולט הסתברות משוערכת שתמונת הקלט הינה "אמיתית" (שייכת לטריין סט). המאמר מציע לנצל את ההתפלגות על מרחב התמונות המושרית ע"י D בשביל לתקן את התפלגות התמונות הנבנות ע"י גנרטור (G).

רעיון בסיסי: כאשר D מאומן בצורה טובה הוא משרה באופן לא מפורש התפלגות על מרחב התמונות כאשר תמונות ש "נראות דומות לטבעיות" מקבלות הסתברויות גבוהות והתמונות ה "לא אמיתיות" מקבלות הסתברויות נמוכות. בעיקרון הרבה יותר הגיוני לדגום מההתפלגות המושרית ע"י D כי אז אנו נדגום תמונות שהוא נותן להם הסתברות גבוהה יותר בסבירות יותר גבוהה. אבל איך נוכל לדגום מההתפלגות הזו אם היא לא ניתנת להסקה (intractable). כדי להתגבר על כך מחברי המאמר משתמשים בדגימות של G ואז מפעילים טכניקת דגימה הנקראת rejection sampling (RS) בשביל "להפוך" את הדגימות אלו לדגימות של D.

תקציר מאמר: מהמבט הראשון הרעיון הזה לא נראה כזה מועיל (וזו הסיבה שבחרתי במאמר הזה לסקירה). הרי אם היה מידע מועיל כלשהו במשקלים של D, הוא היה אמור להיות מועבר במהלך האימון ל G (הרי GAN מתבסס על הרעיון הזה). מתברר שיכולים להיות כמה סיבות לכך.

1. ההנחות על תהליך האימון של GAN לא תמיד מתקיימות (למשל הן ל-D והן ל-G יש קיבולת סופית ולא תמיד ניתן להעביר את כל האינפורמציה מאחד לשני במרחב פרמטרים - (לא במרחב פונקציות התפלגות עצמן)
2. ייתכן שקיימים מצבים שבהם הרבה יותר קל ל-D להבדיל בין התפלגות נכונה ללא נכונה (על סמך דגימות) מאשר למדל התפלגות נכונה ב-D.
3. הסיבה הכי פשוטה: ייתכן שאנחנו לא מאמנים GAN מספיק זמן בשביל ש-G יהיה מסוגל למדל את ההתפלגות האמיתית.

נתחיל מהסבר קצר על rejection sampling המהווה את אבן היסוד של הרעיון המוצע במאמר:

Rejection sampling(RS)

טכניקה זו מיועדת לדגימה מהתפלגויות p_d שהדגימה הישירה ממנה קשה (למשל מהתפלגות שניתנה בצורה לא נורמלית). במקום זאת דוגמים מהתפלגות אחרת p_g שצריכה לקיים תנאי אחד: המקסימום של היחס בין הערכים של p_d ל p_g על כל הנקודות במרחב שלהם צריך להיות חסום ע"י איזשהו קבוע M . אז איך זה בעצם עובד? דוגמים מ p_g נקודה x ומחשבים את הערך של p_d ב x . אז מחלקים את הערך של p_d ומחלקים אותו בערך של p_g המוכפל ב M . אז מקבלים את הדגימה x בהסתברות שווה למנה שחושבה ודוחים אותה אחרת.

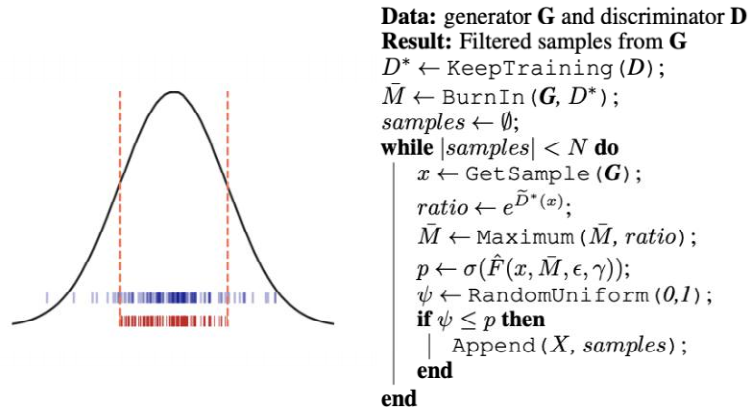


Figure 1: **Left:** For a uniform proposal distribution and Gaussian target distribution, the blue points are the result of rejection sampling and the red points are the result of naively throwing out samples for which the density ratio $(p_d(x)/p_g(x))$ is below a threshold. The naive method underrepresents the density of the tails. **Right:** the DRS algorithm. *KeepTraining* continues training using early stopping on the validation set. *BurnIn* computes a large number of density ratios to estimate their maximum. \bar{D}^* is the logit of D^* . \hat{F} is as in Equation 8. \bar{M} is an empirical estimate of the true maximum M .

אז איך אנו בעצם נבצע RS אם אנו לא יודעים לחשב לא את p_g ולא את p_d בצורה מפורשת? הטריק הוא שאנו צריכים לחשב את המנה ולא את הערכים עצמם ותחת תנאים מסוימים על p_g ו- p_d ניתן לדגום את p_d דרך p_g בצורה מדויקת ("התנאים האידיאליים")

התנאים האידיאליים:

1. ל- p_g ול- p_d יש אותו סט תומך (כלומר הן לא שוות ל 0 באותן נקודות)
2. הקבוע M (המקסימום של המנה (p_d/p_g)) ידוע או שניתן לחשב אותו
3. ל G נתון, ניתן לאמן את D עד להבאתו לערכו המינימלי האבסולוטי התיאורטי של הלוס (הערך הזה שווה ל- $4\log$) (כמובן שזה בלתי אפשרי כי יש לנו דאטה סטים בגודל סופי והאימון שלנו הוא גם באורך סופי)

תחת תנאים אלו המחברים מוכיחים שניתן לדגום מ- p_d דרך p_g עם RS. הנוסחה עבור המנה של p_d ו- p_g במקרה הזה כולל את האקספוננט של הלוג'יט של D^* . ההוכחה הינה אלגנטית ומנצלת את הנוסחה עבור הערך האופטימלי של D בנקודה x (המנה של p_d והסכום p_d ו p_g בנקודה x - נסמן אותו ב- D^*) עבור G קבוע. הערך האופטימלי מוגדר כאן ככזה שמביא את הלוס למינימום האבסולוטי.

כמובן שאף אחד מתנאים אלו לא מתקיימים במציאות.

איך מתגברים על הבעיות הנז"ל ועדיין מבצעים RS:

לגבי תנאים (1 ו-3) הם אומרים שניתן להשתמש ב D המאומן כקירוב מספיק טוב של D^* אם מאמנים את D בצורה מונעת overfitting על הטריין סט (רגולריזציה, עצירה מוקדמת וכדומה). אז D המאומן יודע להבדיל בין דגימה "טובה" לדגימה רעה גם אם הדגימות האלו יהיו בעלות הסתברות 0 עבור p_d אמיתי. הם גם מוכיחים הנחה זו אמפירית.

לגבי (2) הם מציעים לשערך את M בשני שלבים: שלב השערוך שבו הם מחשבים את הערך של M על $K10$ דגימות (נזכיר שעבור דוגמא נתונה M זה האקספוננט של הלוג'יט של הערך של D עבור דגימה זו. אחר כך בשלב הדגימה הם מעדכנים אותו אם מתקבל ערך יותר גבוה. זה עלול ליצור בעיה על הסתברויות קבלת הדגימות עם הערך הישן של M קיבלו ערכים גבוהים מדי אך לטענתם דבר כזה לא קורה הרבה.

בנוסף אציין של- RS יש בעיה לדגום המרחבים בעלי מימד גבוה כי ההסתברות לאי דחיית (קבלה) דגימה הינה מאוד קטנה. הם עושים טריק יפה (אך מעוות את ההתפלגות האמיתית של הסתברויות קבלה) כדי "להתגבר" על הבעיה הזו. הם עושים פרמטריזציה של הביטוי עבור הסתברות קבלה ומכניסים פרמטר האחראי על הרחבת סט הערכים של הסתברות זו. כלומר אם ערך הפרמטר גבוה אז רוב הדגימות מתקבלות ואם הוא נמוך רוב הדגימות נדחות. בסוף עושים אופטימיזציה על הערך של פרמטר זה.

הישגי מאמר: המחברים הצליחו לשפר את איכות התמונות המוגנרטות עי" GAN עם השיטה שלהם. ההשוואה בוצעה מול SAGAN שהיה SOTA על יצירת תמונות (מאומן על Imagenet) לפני כשנתיים.

מטריקות השוואה: Frechet Inception Distance, מרחק Inception

מאמר המשך: - <https://arxiv.org/pdf/1811.11357.pdf> מציע להחליף RS בשיטה יותר רובסטית לדגימה מהתפלגות לא ידועה - Metropolis-Hastings.

לינק למאמר: <https://arxiv.org/abs/1810.06758>

לינק לקוד: לא מצאתי אך יש במאמר המשך - <https://github.com/uber-research/metropolis-hastings-gans>

נ.ב. מאמר עם רעיון מבריק, חסר לי הוכחות ריגורוזיות של ההנחות שלהם ומקווה שיבואו בהמשך

#deepnightlearners