

לילה טוב חברים, היום אנחנו שוב בפינתנו DeepNightLearners (היום טיפה יותר מוקדם) עם סקירה של מאמר בתחום הלמידה העמוקה

היום בחרתי לסקירה את המאמר שנקרא:

Removing Bias in Multi-modal Classifiers: Regularization by Maximizing Functional Entropies
שיצא לפני שבוע בערך. המחברים של המאמר הם חברים בקבוצה הזו (לוקח את הסיכון) והם מוזמנים להגיב ולתקן אותי אם פספסתי משהו.

תחום מאמר: מסווגים מולטימודליים, שיטות רגולריזציה

מאמר הוצג בכנס: NeurIPS 2020

כלים מתמטיים במאמר: אנטרופיה פונקציונלית (FE), אינפורמציה פישר פונקציונלית, אי שוויונות לוגו של סובולב ושל פאונקרה, טנזוריזציה במרחבי הסתברות מכפליים (product probability spaces)

תמצית מאמר: המאמר מציע שיטה להתמודד עם הסטייה בכיוון של תת-קבוצה של מודים בתהליך אימון על בעיות סיווג מולטימודליות. כאשר זה קורה המסווג עלול להיות מוטה כלפי תת-קבוצה של המודים ולהתעלם (להתחשב פחות) מהמודים האחרים. למשל ניקח לדוגמה דאטה סט הנקרא Colored MNIST שסט האימון וסט הוולידציה שלו מכילים תמונות צבעוניות של הספרות, והטסט סט מכיל תמונות בגווני אפור. אם מאמנים רשת נוירונים עם לוס רגיל במטרה לסווג את הספרה, ביצועיה (דיוק) על הטסט סט סופגים ירידה משמעותית יחסית לביצועים על סט האימון ועל סט הוולידציה. הסיבה לכך היא שהמסווג למד להתחשב בעיקר בצבע של תמונה (המוד הראשון) ומתעלם לרוב מהצורה של הספרה (המוד השני). עוד דוגמה לכך, היא משימת "מענה על שאלות ויזואליות" (מולטימודלית בצורה אינהרנטית) כאשר המסווג תמיד יבחר במודים של המענה ויתעלם מהמודים היותר מתאימים. בשביל להתמודד עם סוגייה זו המחברים מציעים להוסיף לפונקציית לוס איבר שמנסה "להכריח כל מוד לתרום" לסיווג הסופי. איבר זה מבוסס על FE, שבעזרתה ניתן לאמוד את התרומה של כל מוד לתוצאה של המסווג.

במילים אחרות FE משערכת את "מידת השתנות הממוצעת של התפלגות הפלט של המסווג עבור פרטורבציות (הרעשה) של הקלט" (במרחבי הייצוג ולא במרחבים המקוריים!!) תחת התפלגות מסוימת על הפרטורבציות (המאמר משתמש בהתפלגות גאוסית באופן טבעי). ככל שמידת השתנות זו קטנה יותר עבור סיווג נתון (כלומר התפלגות של פלט המסווג איננה משתנה בהרבה עבור נקודות בסביבה יחסית רחוקה של האינפוט - במרחב הייצוג), המסווג נוטה "לא לנצל מידע על לפחות חלק מהמודים באופן מיטבי".

בנוסף מכיוון FE קשורה לשונות של מידת השתנות של התפלגות הפלט, המאמר מציע להוסיף את איבר המשערך שונות זו במקום האיבר של FE. למעשה, ככל שהשונות של מידת הששתנות קטנה יותר, התפלגות הפלט פחות תלויה באינפוט שזה כמובן לא רצוי. מעניין שאיבר רגולריזציה בצורה של שונות משיג שיפור מסוים בביצועים עבור כמה משימות.

רעיון בסיסי: הרעיון הבסיסי של המאמר הוא להוסיף איבר המשערך FE לפונקציית לוס רגילה (קרוס-אנטרופי). מידת ההשתנות של פלט המסווג עבור פרטורבציות (הרעשה) של דוגמה נתונה מוגדרת במאמר בתור קרוס אנטרופי בינה לבין התפלגויות הפלט שלה (הקלט הנקי והקלט מורעש).

תקציר מאמר: בעיה העיקרית עם באנטרופיה הפונקציונלית נעוצה בכך שלא ניתן לחשב אותה באופן ישיר, אלא רק באמצעות דגימות של האינטגרנד. בנוסף לכך, FE מכילה איבר **לוג** של אינטגרל התוחלת ששיעורו ע"י דגימות עלול להיות מאוד לא מדויק.

אינפורמציה פישר פונקציונלית: המאמר מציע להשתמש בחסם מלעיל ל- FE (הנובע מאי שוויונות לוג של סובולב) ע"י אינפורמציה פישר פונקציונלית (FFI), המהווה הכללה של אינפורמציה פישר קלאסית. כמו שאתם אולי זוכרים,

אינפורמציה פשוט רגילה (FI) מודדת עד כמה מידע יש בדגימות של משתנה מקרי X המפולג עם פונקציה התפלגות f התלויה בפרמטר t , על הפרמטר הזה. FI מוגדרת בתור תוחלת לפי f של הנגזרת הרביעית לפי t של הלוג של f . עבור ערך פרמטר נתון FI משערכת את "מידת הקשר" בין ערכו של הפרמטר לבין הדגימות של המשתנה המקרי X . כלומר ככל ש-FI יותר גבוה ניתן לשערך את הפרמטר ביותר דיוק (אפשר להסיק זאת גם מאי השוויון של ראו-קרמר - הדיוק נמדד שם ע"י שגיאת שערך ריבועית הממוצעת).

אז ההכללה של FFI מתבטאת בכך שמכפילים את האינטגרנד בפונקציית התפלגות נוספת (במקרה שלנו זה פונקציה התפלגות על הפרטורבציות של נקודות הדאטה $f_{\text{per}}(z)$). זה מאפשר להחליף את פונקציה הצפיפות f המופיעה בביטוי המקורי של FI בכל פונקציה אי שלילית (במקרה שלנו הפונקציה הזו היא קרוס-אנטרופי בין התפלגויות של הפלטים $f_{\text{ce}}(z)$). בדומה ל FI, FFI גם משערך את מידת ההשתנות של $f_{\text{ce}}(z)$ כאשר הפרמטר שלה z מתפלג עם $f_{\text{per}}(z)$.

חסם לוג של סובולב על FFI: סובולב מאפשר לחסום את FE מלמעלה ע"י האינטגרל המכיל מנה של הנורמה של הגרדיאנט הריבועי של קרוס-אנטרופי בין התפלגויות של הפלטים $f_{\text{ce}}(z)$ ו- $f_{\text{ce}}(z)$ עצמם ששניהם ניתנים לחישוב בצורה מפורשת וניתן להכניסם כמו שהם לפונקציה לוס.

טנזוריזציה של FE לבעיות מולטימודליות: המאמר מציין שנקודה במרחב הלטנטי של במשימה מולטימודליות עשויה להיות מורכבת מכמה מודליות מהמרחבים הלטנטיים השונים. למשל במקרה של משימת מענה על שאלות ויזואליות המרחב הלטנטי הוא בעצם מרחב פרודקט של שלושה מרחבים: ייצוג התמונה, ייצוג השאלה וייצוג התשובה. המאמר מראה שבמקרים כאלו ניתן את FE של נקודת דאטה של הסכום של האיברים שכל אחד מהם זה FE הממוצע של כל מודל z_i , כאשר הממוצע המחושב על מרחב הפרודקט של שאר המודלים (פרט ל i) עם פונקציות התפלגות המורכבת ממכפלה של $f_{\text{per}}(z_j)$ (פרט ל i). ייצוג זה נקרא טנזוריזציה והוא מאפשר לחשב חסם על FI של נקודת דאטה בצורה יחסית קלה. כרגע יש לנו את כל הכלים בשביל לתאר את המבנה של פונקציה לוס המוצעת. לפני שנעבור לתיאור של פונקציה הלוס נדון קצרות בצורה השנייה של איבר רגולריזציה המוצע במאמר קרי שונות של $f_{\text{ce}}(z)$ תחת $f_{\text{per}}(z)$.

איבר רגולריזציה בצורה של שונות של $f_{\text{ce}}(z)$: ראשית, המאמר מציין שקיים קשר בין FFI לשונות של $f_{\text{ce}}(z)$ כאשר תקף עבור ערכים קטנים של $f_{\text{ce}}(z)$. באופן אינטואיטיבי ככל ש FFI של פונקציה $g(z)$ יותר גבוה אז השונות נוטה להיות גבוהה יותר כי שניהם מתארים את מידת השתנות של $g(z)$ תחת אותה מידת הסתברות. בדומה ל FFI גם השונות לא ניתנת לחישוב בצורה מפורשת (רק ע"י דגימות) ואז המאמר משתמש באי שוויון פואנקרה בשביל להקל על החישוב. לבסוף מבצעים טנזוריזציה של הביטוי המתקבל (משתמשים במשפט אפרון-שטרן) כדי לקבל את הביטוי הסופי.

מבנה של פונקציה לוס: מכיוון שהמטרה שלנו היא למקסם את FFI, איבר רגולריזציה המתווסף לפונקציה לוס מכיל את ההופכית של החסם על FFI (או שונות) ומחברים אותו ללוס קרוס-אנטרופי סטנדרטי. זה כל הסיפור ואפשר להתחיל את האימון.

הישיג מאמר: המאמר מדווח על השיפור בדיוק על 4 דאטה סטים מולטימודליים מול כמה גישות עדכניות

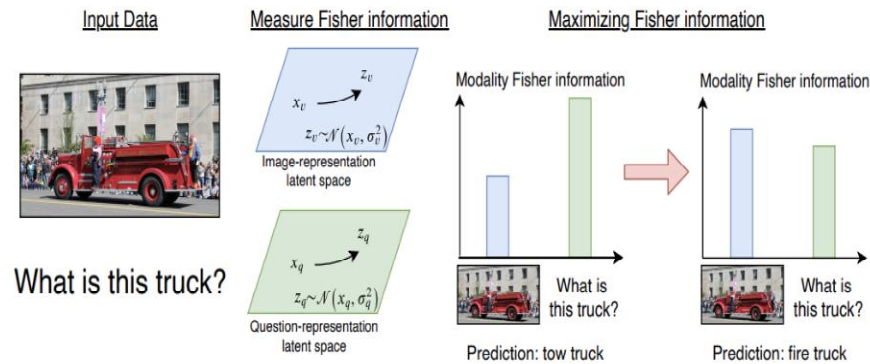


Figure 1: We illustrate our approach. In the visual question answering task, we are given a question about an image. Thus, we can partition our input into two modalities: a textual modality, and a visual modality. We measure the modalities' functional Fisher information by evaluating the sensitivity of the prediction by perturbing each modality. We maximize the functional Fisher information by incorporating it into our loss as a regularization term. Our results show that our regularization permits higher utilization of the visual modality.

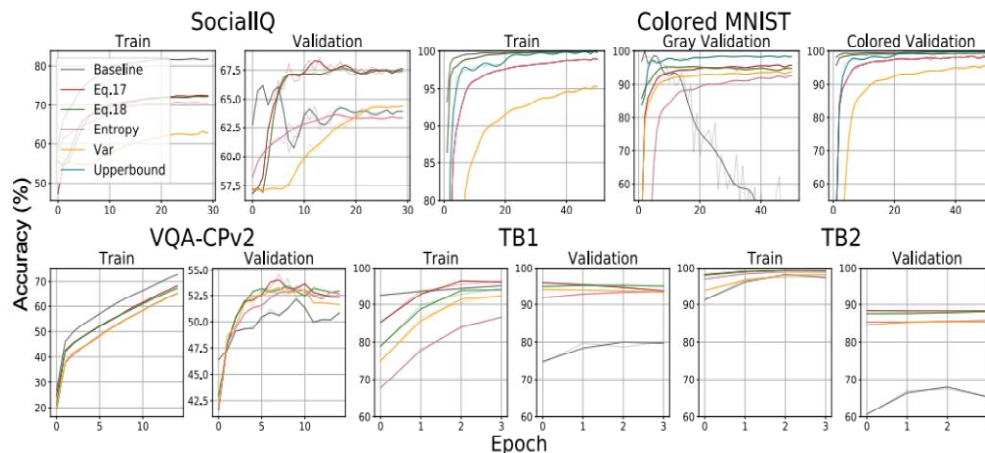


Figure 3: Training process with and without regularization. We note that generalization significantly improves when using our proposed regularization.

דאטה סטים :

- Dogs and Cats
- SocialIQ (הבנת מצבים בוידאו)
- Colored MNIST (מענה על שאלות ויזואליות)
- VQA-CPv2

לינק למאמר: <https://arxiv.org/abs/2010.10802>

לינק לקוד: <https://github.com/itaigat/removing-bias-in-multi-modal-classifiers>

נ.ב. הרעיון של המאמר די מגניב, לקח לי זמן להבין אותו כי המתמטיקה במאמר די קשוחה. מצפה לראות שימושים של טכניקה זו למגוון רחב של בעיות מולטימודליות (למשל ב בלמידת חיזוק עמוקה)