

לילה טוב חברים, היום אנחנו שוב בפינתנו deepnightlearners עם סקירה של מאמר בתחום הלמידה העמוקה  
היום בחרתי לסקירה את המאמר שנקרא: Supermasks in Superposition

שפורסם לפני כ 4 חודשים (הגרסה האחרונה הועלת לארקיב לפני שבועיים).

תחומי מאמר: שיטות למידה מתמשכת (continual learning) ברשתות נוירונים, למידת משימות מרובות (multi-task learning).

מאמר הוצג בכנס: NeurIPS 2020

כלים מתמטיים, מושגים וסימונים: מסכות בינאריות על משקלים ברשתות נוירונים, שכחה קטסטרופית ברשתות, רשתות הופילד (HP), אנטרופיה (זה המושג המרכזי שעליו המאמר בנוי)

תמצית מאמר: המאמר מציע שיטה אימון SupSup של רשת נוירונים גדולה (נקרא לה רשת בסיס) המקנה להם יכולת לבצע כמה משימות שונות. המשקלים של רשת הבסיס הינם קבועים לכל המשימות. בעצם לוקחים רשת, מאתחלים את משקליה באופן רנדומלי ומשתמשים באותה רשת לחיזוי עבור משימות שונות. הדרך לבצע זאת זה ללמוד סט מסכות בינאריות נפרד (0 או 1) לכל משימה ועבור כל משימה "להלביש את סט המסכות" שלה על רשת הבסיס בזמן אינפרנס. בעצם מסכה בינארית כזו מדליקה או מכבה קשרים בין נוירונים שונים ברשת. בדרך זו מתגברים על תופעת השכחה הקטסטרופית שעלולה להתרחש אם מאמנים רשת משימה אחרי משימה

המאמר מגדיר 4 תרחישים טיפוסיים עבור משימות הלמידה המתמשכת ומציע שיטה לאמן רשת בסיס לביצוע של טאסקים מרובים עבור כל אחת מהם:

- המשימות ידועות (מזוהות) גם במהלך האימון וגם באינפרנס (כלומר כל פעם שאנו מקבלים משימה אני יודעים איזו משימה זו): מסומנת עי" GG
- המשימות ידועות במהלך האימון ולא ידועות במהלך האינפרנס (עם לייבלים משותפים). קרי אנחנו צריכים לנחש איזו משימה קיבלנו באינפרנס בשביל להבין לאיזה טאסק באימון היא שייכת (איזו מסכה לבחור) - GNs
- המשימות ידועות במהלך האימון ולא ידועות במהלך האינפרנס עם לייבלים שונים. כלומר שכבת היציאה של הרשת צריכה להיות בגודל סכום של מספר הלייבלים עבור כל המשימות - GNu
- המשימות לא ידועות לא בזמן האימון ולא בזמן האינפרנס (הלייבלים חייבים להיות משותפים כאן). כאן באימון אנו מקבלים משימה ולא יודעים איזו משימה קיבלנו. כלומר כל פעם אנו צריכים להחליט האם להשתמש במסכה הקיימת או לאמן מסכה חדשה. דבר דומה קורה גם באינפרנס: NN

רעיונות בסיסיים: יש כמה רעיונות מעניינים במאמר. ניתן להפריד אותם בגדול לשני סוגים:  
1. שיטות לפתרון לכל התרחישים, המתוארים מעלה, של בעיות הלמידה המתמשכת

- משימות GG: לבחור מסכה המתאימה עבור משימת אינפרנס
- משימות GN ו-GNu: המאמר מציע לתאר את המסכה עבור משימת אינפרנס כצירוף לינארי של כל המסכות שאומנו ולחפש את המקדמים ע"י מציאת המקדם שהעלייה בו מביאה לירידה הכי גדולה באנטרופיה של פלט הרשת עבור המשימה. כלומר המקדם שהגרדיאנט של האנטרופיה השלילית (מוכפלת ב-1) של רשת הבסיס לפיו הינה מקסימלית. זה מאפשר לא להריץ את הרשת עבור כל מסכות בזמן אינפרנס (אם יש מאות רבות או אלפי מסכות ודאטה סטים גדולים, זה יכול להיות משמעותי). במקום זאת מריצים את המשימה ברשת פעם אחת עם ממוצע של כל המשקלים

(הם קוראים לזה One-Shot) ומחשבים את הגרדיאנט. נציין ש-One-Shot מבוסס על גרדיאנט אחד בלבד של אנטרופית רשת הבסיס שהיא פונקציה לא קמורה ביחס למקדמים של המסכות. עובדה זו עלולה להביא לבחירה של מסכה לא נכונה. בשביל להתגבר על בעיה זו הם הציעו לבחור את המקדם בתהליך איטרטיבי. כל פעם מאפסים חצי מהמקדמים עם גרדיאנטים הכי נמוכים עד שנשארים עם מסכה אחת.

- משימות NN: עושים משהו דומה לסעיף הקודם אבל אם לא נמצא מקדם שהשינוי בו מביא לעלייה משמעותית באנטרופיה (מחשבים softmax על כל הגרדיאנטים), מאמנים מסכה חדשה. אחרת לוקחים את המקדם עבורו התקבל המקסימום משתמשים במסכה שלו. דרך אגב הם לא ציינו את אופציה נוספת: במקום לאמן מסכה חדשה (במקרה שצריך) אפשר לאמן מקדמים של הקומבינציה הלינארית הכי אופטימליים מבחינת הביצועים - הרי צריך פחות מקום בשביל לאחסן את המקדמים מאשר המסכה.
- בנוסף הם מציעים איזה טריק נחמד התורם משמעותית לשיפור בביצועים. הם מוסיפים "לייבלים מלאכותיים" כלומר להוסיף נירונים לשכבה האחרונה של רשת הבסיס. למשל אם אנו מאמנים מסווג MNIST עם 10 קלאסים אז השכבה האחרונה תכלול, נגיד, 100 נירונים כאשר 90 הנירונים שהוספו ל-10 הרגילים שייכים לקלאסים "לא קיימים". המאמר מנצל את ערכי הנירונים האלו בשביל להחליף את מדד הנגזרת לפי מקדמים של הקומבינציה הלינארית של המסכות.

## 2. שיטות לשמירה יעילה ולהפקת מסכה מתאימה למשימה (עבור משימות GN)

המאמר מציע לשמור מסכות ברשת הופפילד כאשר שומרים את הכל המסכות בתוכה עי" ביצוע עדכון המשקלים שלה (של HP). בזמן האינפרנס מנסים לאתר את המסכה האופטימלית עי" חיפוש מינימום של הסכום הממשוקל של פונקציית האנרגיה של HP (הלוס הרגיל שלה) והאנטרופיה של המסכה ברשת הבסיס (עבור המשימה שבנידון).

אנטואיציות: עכשיו ניקח כל רעיון המוצע במאמר וננסה להבין את הרציונל מאחוריו.

גרדיאנט של אנטרופיית שכבת פלט של רשת בסיס ביחס למקדמים של קומבינציה לינארית של מסכות: קודם כל ככל שהרשת יותר בטוחה בחיזוי של עבור דוגמא מסוימת האנטרופיה של שכבת הפלט שלה תלך ותורד. למשל לוקטור פלט  $[0.05, 0.9, 0.05]$  (הרשת "ממש בטוחה" בחיזוי שלה) יש אנטרופיה נמוכה הרבה יותר מוקטור  $[0.3, 0.3, 0.45]$  (הרשת לא "בטוחה"). אז אם גרדיאנט של אנטרופיית שלילית של הרשת הוא גבוה עליה במקדם זה תוביל לעלייה באנטרופיה השלילית כלומר לירידה באנטרופיה. ההנחה כאן שאם הרשת פולטת חיזויים "בטוחים" עבור מסכה מסוימת אז כנראה שקיבלנו משימה דומה לזו שהמסכה הזו אומנה. שימו לב שהאנטרופיה ממוחשבת על כל הטריין סט של המשימה שהופך את ההנחה הזו לסבירה.

הוספה של לייבלים מלאכותיים לשכבת הפלט: זה רעיון שמאוד אהבתי - כאשר אנו מאמנים רשת עם יותר נירונים בשכבת הפלט עבור משימה מסוימת הרשת לומדת לשים של ערכים שליליים גבוהים בערך המוחלט (ההופכים לאפס softmax לאחר מכן). אז אם באינפרנס אנחנו מקבלים שם ערכים שהם לא שליליים גבוהים זה סימן שמשימה זו אינה תואמת למשימה עליה מסכה זו אומנה. אז במקום להשתמש באנטרופיה המאמר מציע לחשב את הלוגריתם סכום האקספוננטים של הערכים בנירונים המלאכותיים של השכבה האחרונה. אם יוצא ערך גבוה אז המסכה לא מתאימה למשימה. עם כל היופי ברעיון הזה יש לי תחושה שניתן להשיג תוצאה דומה דרך הכנסת טמפרטורה בסיגמואיד למשחק.

שמירה של מסכות ברשת הופפילד: בשביל לחסוך במקום אחסון של המסכות המאמר מציע לשמור אותם ב רשת הופפילד. HP זה בעצם מטריצה הבנויה בשביל לאחסן (בצורה חסינה נגד רעש) וקטורים המורכבים מ  $\{-1, 1\}$  (המסכות מורכבות מ  $\{0, 1\}$  אז עושים טרנספורמציה פשוטה בשביל להפוך אותם לפורמט של HP). כל פעם

שרוצים לאחסן וקטור נוסף ב HP מעדכנים את המטריצה שלה עם הווקטור הזה (יש כמה דרכים לעשות זאת - הם השתמשו בכלל עדכון של סטורקי). אז איך קוראים ממטריצת הזכרון הזה? נגיד קיבלנו גרסה מורעשת של וקטור, מזינים אותו לפונקציות אנרגיה המוגדרות ע"י מטריצה זו (בגדול זה צורה ריבועית שלה) ומנסים להביא אותה למינימום. ניתן להוכיח המינימום מתקבל בנקודה השמורה הכי קרובה לקלט המורעש. אבל במקרה שלנו (זה עובד רק בתרחיש GN) אנחנו לא רק צריכים לאתר את הווקטור השמור הקרוב ביותר לקלט (שהוא תמיד ממוצע של כל המסכות) אלא למצוא מסכה שמביאה למינימום את האנטרופיה של פלט הרשת. אז הם הוסיפו ללוס הרגיל של HP איבר המכיל אנטרופיה של הרשת. בעצם הלוס הינו צירוף לינארי של לוס HP רגיל עם מקדם העולה עם האיטרציות והלוס של אנטרופיה היורד עם מספר האיטרציות. האינטואיציה כאן שבהתחלה זזים בכיוון של המסכה הנכונה וכאשר אנחנו באיזור מבצעים תהליך רגיל של מינימיזציה אנרגיה של HP.

ולסיום אני רוצה לציין שהמאמר משתמש ברשת בסיס די גדולה ומאוד overparameterized. זה מאפשר למצוא מסכות, המאפסות הרבה מהמשקלים שלה, שניתן לאמן אותן לביצוע של משימות שונות. דרך אבב הם לא ציינו איך מתבצע האימון של כל מסכה פר משימה (יש מגוון שיטות)

הישיג מאמר: הם מוכיחים את העליונות של השיטה שלהם בכל התרחישים המתוארים מעלה וגם מראים שהביצועים שלהם לא רחוקים מהביצועים האופטימליים של רשת הבסיס למשימה (כאשר הרשת מאומנת לכל משימה בנפרד מחדש). הם גם מראים חיסכון משמעותי במקום איחסון לשיטות עם ביצועים דומים. בנוסף הם גם מראים שהגישה שלהם מאפשרת לאמן אלפי משימות על רשת בסיס אחת עם ביצועים הלא נופלים בהרבה מהביצועים המקסימליים

דאטה סטים:

SplitCIFAR100, SplitImageNet :GG  
PermutedMNIST, RotatedMNIST, and SplitMNIST :GN  
PermutedMNIST :NN

לינק למאמר: <https://arxiv.org/pdf/2006.14769.pdf>

לינק לקוד: לא מצאתי

נ.ב. המאמר מציע שיטה מבריקה לאימון רשת אחת לביצוע של מספר גדול של משימות. אבל צריך לזכור כמה דברים:

1. המשימות שהם אימנו הם באותה דרגת קושי (אני לא בטוח שהעסק יעבוד חלק אם המשימות היו בדרגות קושי שונות - אולי אז צריך לשחק עם מספר האחדים לכל מסכה בנפרד או משהו כזה)
2. המשימות שאומנו הן דומות מבחינה סמנטית. הם לא ניסו לשלב דאטה סטים מדומיינים שונים
3. המשימות שהם אימנו עליהם הן לא קשות ונשאלת השאלה אולי מבחינת מקום אחסון עדיף לאמן רשת קטנה לכל משימה?

#deepnightlearners